

Documento Consolidado — Dados BDGD/ANEEL (AT, MT e BT)

Síntese dos três níveis de tensão e guia de tratamento para o banco de dados — Planejamento Otimizado de Cobertura de RF para Redes de Sensores em Sistemas de Distribuição de Energia

1. Visão geral consolidada

Este documento reúne o que foi levantado nos três dicionários de dados anteriores (UCAT_PJ, UCMT_PJ e UCBT) em uma única referência, focada em como as três bases se conectam e em como tratá-las para subir a um banco de dados único.

Nível	Arquivo	Registros originais	Colunas originais	Colunas após tratamento	Situação
Alta Tensão (AT)	ucat_pj.csv	2.122	101	~15	Recebido e anal
Média Tensão (MT)	ucmt_pj.csv	314.493	80	~16	Recebido e anal
Baixa Tensão (BT)	UCBT (~5 GB)	Não calculado (arquivo não enviado)	70	~15	Só a estrutura d recebida — falta do CSV para nún

2. A cadeia elétrica completa

Os três arquivos são a mesma base regulatória (BDGD/ANEEL, Módulo 10 do PRODIST), cada um representando um nível de tensão. Eles se conectam por uma hierarquia elétrica real, não por chaves estrangeiras clássicas de banco:

- SUB (subestação) → CTAT (circuito de AT) → UCAT — consumidor de alta tensão.
- SUB → UNI_TR_AT (transformador AT/MT) → CTMT (circuito de MT) → UCMT — consumidor de média tensão.
- SUB → UNI_TR_AT → CTMT → UNI_TR_MT (transformador MT/BT) → RAMAL (ramal de ligação) → UCBT — consumidor de baixa tensão.

Ou seja: a mesma subestação (SUB) alimenta os três níveis; cada nível de tensão é uma etapa de rebaixamento a partir da anterior. A BT carrega o rastro mais completo (chega a referenciar até o transformador de AT de origem).

2.1 As chaves que realmente ligam as três tabelas

Campo(s)	Decisão	O que representa
CONJ	É o vínculo mais forte	Testado entre UCAT_PJ e UCMT_PJ: 100% dos códigos CONJ do UCAT_PJ também aparecem no UCMT_PJ (950 de 950). É a chave recomendada para agrupar os três níveis em uma mesma área de planejamento de cobertura.
SUB	Vínculo direto na hierarquia	Mesma subestação nas três tabelas, mas com sobreposição parcial entre arquivos (400 de 1.500 SUBs do UCAT_PJ reaparecem no UCMT_PJ) — os arquivos cobrem áreas geográficas de tamanhos diferentes.
UNI_TR_AT	Vínculo com a camada de AT	Presente em UCMT_PJ e UCBT. Referencia um equipamento (transformador AT/MT), não uma linha do UCAT_PJ — um vínculo exato exigiria a entidade UNTRAT da BDGD, que não está nos três arquivos que você enviou.
UNI_TR_MT	Vínculo com a camada MT/BT	Só existe na UCBT. Identifica o transformador de distribuição (MT/BT) que atende aquele grupo de UCs de baixa tensão.

Campo(s)	Decisão	O que representa
CTMT	Vínculo de circuito	Compartilhado por UCMT_PJ e UCBT — o mesmo circuito de MT pode alimentar UCs de MT diretamente e transformadores que atendem UCs de BT.
MUN, DIST	Vínculo de contexto	Mesma codificação nas três tabelas — servem para filtrar por cidade/distribuidora, não indicam ligação elétrica ponto a ponto.
COD_ID_ENCR, PN_CON, PAC, RAMAL	Não são vínculo entre as tabelas	Mesmo nome de coluna nas três tabelas, mas cada uma identifica pontos de conexão distintos de cada nível — nunca use esses campos para tentar cruzar AT, MT e BT entre si.

3. Dicionário consolidado — o que cada campo carrega

Resumo dos grupos de campos comuns aos três arquivos, e o que muda em cada nível.

Grupo de campos	Presente em	Resumo
COD_ID_ENCR, PN_CON, PAC (+ RAMAL na BT)	AT, MT, BT	Identificadores da unidade consumidora e do seu ponto de conexão — únicos dentro de cada tabela, não cruzam entre níveis.
DIST, SUB, CONJ, MUN, CEG_GD	AT, MT, BT	Identificação da distribuidora e da hierarquia elétrica/geográfica — SUB e CONJ são as chaves de ligação entre os três níveis.
LGRD, BRR, CEP	AT, MT, BT	Endereço textual — redundante com POINT_X/POINT_Y para fins de geolocalização.
CLAS_SUB, CNAE, TIP_CC	AT, MT, BT	Classificação do consumidor (indústria, comércio, rural, poder público etc.) — indicador de criticidade.
FAS_CON, GRU_TEN, TEN_FORN, GRU_TAR	AT, MT, BT	Características elétricas de faturamento — GRU_TEN muda por arquivo (AT/MT/BT) mas é constante dentro de cada um.
SIT_ATIV, DAT_CON, LIV	AT, MT, BT	Situação cadastral da UC — SIT_ATIV é o campo usado para filtrar apenas conexões ativas.
CAR_INST, ARE_LOC, TIP_SIST	AT, MT, BT	Porte da carga e contexto de rede — ARE_LOC (urbano/rural) e TIP_SIST (interligado/isolado) impactam diretamente o modelo de propagação de RF.
DEM_CONT + DEM_P/F_01..12 (ponta/fora-ponta)	Só AT	Demanda contratada e medida, com separação ponta/fora-ponta — típico de grandes consumidores de alta tensão.
DEM_01..12 (série única)	Só MT	Demanda medida sem separação ponta/fora-ponta.
Sem campo de demanda	BT	Baixa tensão não tem medição de demanda, só de energia (ENE_*).
ENE_P/F_01..12 (ponta/fora-ponta)	Só AT	Energia consumida com separação ponta/fora-ponta.
ENE_01..12 (série única)	MT, BT	Energia consumida por mês, sem separação ponta/fora-ponta.
DIC_01..12, FIC_01..12	AT, MT, BT	Indicadores individuais de continuidade (duração e frequência de interrupção) — o melhor sinal disponível para priorizar cobertura por criticidade de falha.
SEMRED, DESCR, DATA_BASE	MT, BT (SEMRED/DATA_BASE); todos (DESCR)	SEMRED indica UC sem segmento de rede associado no cadastro geográfico; DATA_BASE é a data de referência do extrato; DESCR é campo livre, quase sempre vazio.
POINT_X, POINT_Y	AT, MT, BT	Coordenadas geográficas — a entrada geoespacial bruta para todo o planejamento de cobertura.
CTAT	Só AT	Circuito de alta tensão que alimenta diretamente a UC.
CTMT	MT, BT	Circuito de média tensão.
UNI_TR_AT	MT, BT	Transformador AT/MT de origem.
UNI_TR_MT	Só BT	Transformador MT/BT que atende a UC de baixa tensão.
OBJECTID	Só BT	Índice técnico do GIS de origem, sem significado elétrico.

4. O que manter, agregar ou descartar — visão unificada

A mesma lógica foi aplicada nos três documentos: um campo só é mantido se muda alguma decisão do planejamento de cobertura de RF. Consolidando:

4.1 Manter nas três tabelas

- Identificação: COD_ID_ENCR (chave primária de cada tabela).
- Geolocalização: POINT_X, POINT_Y.
- Contexto geográfico: MUN, BRR, ARE_LOC.
- Topologia elétrica: SUB, CONJ, e o(s) circuito(s)/transformador(es) de cada nível (CTAT na AT; CTMT e UNI_TR_AT na MT; CTMT, UNI_TR_AT e UNI_TR_MT na BT).
- Classificação/criticidade do consumidor: CLAS_SUB, CNAE, CAR_INST (e DEM_CONT quando existir — AT e MT).
- Contexto de rede: TIP_SIST.
- Filtro: SIT_ATIV (usado para filtrar 'AT' = ativa e depois pode ser descartado).

4.2 Agregar antes de subir (em todas as três)

- DIC_01..12 → somar em DIC_TOTAL_ANO (horas de interrupção no ano).
- FIC_01..12 → somar em FIC_TOTAL_ANO (nº de interrupções no ano).
- Campos de demanda/energia mensais (DEM_*/ENE_*, onde existirem) → agregar em médias anuais só se forem realmente usados; caso contrário, descartar — DEM_CONT/CAR_INST já cobrem a necessidade de indicar criticidade.

4.3 Descartar nas três tabelas

- Identificadores de conexão comercial/de nó muito granulares (PN_CON, PAC, RAMAL) — redundantes com COD_ID_ENCR para o nível de cobertura macro do projeto.
- Campos constantes dentro de cada arquivo (DIST, GRU_TEN) e quase sempre vazios (CEG_GD, DESCR).
- Endereço textual (LGRD, CEP) — redundante com POINT_X/POINT_Y, salvo se precisar exibir endereço legível em relatório.
- Detalhes de faturamento sem efeito na cobertura de RF (FAS_CON, TIP_CC, TEN_FORN, GRU_TAR, DAT_CON, LIV).
- Metadados técnicos do arquivo de origem (DATA_BASE, OBJECTID) e SEMRED (mas vale conferir antes se algum registro das duas cidades tem SEMRED = 1).

5. Modelagem sugerida para o banco de dados

Recomendação: manter três tabelas separadas — uma por nível de tensão — em vez de uma tabela única, porque cada nível tem campos próprios (ex.: DEM_CONT só existe em AT/MT; UNI_TR_MT só existe em BT) e o volume de dados é muito diferente entre elas (2 mil x 314 mil x provavelmente milhões de linhas na BT).

5.1 Estrutura de tabelas

```
ucat_pj (cod_id_encr PK, mun, brr, point_x, point_y, are_loc, sub, conj, ctat, clas_sub, cnae, car_inst, dem_cont, tip_sist, dic_total_ano, fic_total_ano)
```

```
ucmt_pj (cod_id_encr PK, mun, brr, point_x, point_y, are_loc, sub, conj, ctmt, uni_tr_at, clas_sub, cnae, car_inst, dem_cont, tip_sist, dic_total_ano, fic_total_ano)
```

```
ucbt (cod_id_encr PK, mun, brr, point_x, point_y, are_loc, sub, conj, ctmt, uni_tr_mt, uni_tr_at, clas_sub, cnae, car_inst, tip_sist, dic_total_ano, fic_total_ano)
```

5.2 Como ligar as três tabelas

- Não existe (nem deve ser forçada) uma foreign key linha a linha entre ucat_pj, ucmt_pj e ucbt — a ligação é por agrupamento, não por registro individual.
- Para consultas que cruzam os três níveis (ex.: 'todos os pontos, de qualquer tensão, dentro da mesma área de planejamento'), use CONJ como chave de agrupamento — é a mais confiável, já validada entre AT e MT.
- Se quiser evitar repetir o mesmo conjunto de metadados (DIST, SUB, CONJ, MUN) em três lugares, uma opção é criar uma tabela auxiliar de dimensão, por exemplo dim_conjunto (dist, sub, conj, mun) — com um registro por combinação única — e as três tabelas principais referenciam essa dimensão por SUB + CONJ.
- Para consultas espaciais (distância entre pontos, área de cobertura de um raio de RF), considere um banco com suporte geoespacial (ex.: PostgreSQL + PostGIS) e transformar POINT_X/POINT_Y em uma coluna geometry/geography — isso facilita cálculos de buffer, clusterização e distância que um simples par de colunas numéricas não permite de forma eficiente.

5.3 Cuidados de tipo de dado

- Códigos como COD_ID_ENCR, SUB, CONJ, MUN, CTAT, CTMT, UNI_TR_AT, UNI_TR_MT devem ser armazenados como texto (varchar/string), mesmo quando parecem números — são identificadores, não quantidades, e podem ter zeros à esquerda ou não ter significado aritmético.
- POINT_X, POINT_Y e CAR_INST/DEM_CONT devem ser numéricos de ponto flutuante (float/double).
- DIC_TOTAL_ANO e FIC_TOTAL_ANO também numéricos (float e inteiro, respectivamente).
- Crie índices em MUN, CONJ, SUB e SIT_ATIV (antes de descartar esse último) — são os campos mais usados para filtrar e agrupar nas consultas do projeto.

6. Fluxo de trabalho recomendado, passo a passo

1. Filtrar cada um dos três arquivos por MUN em ['3549904' (São José dos Campos), '3508504' (Caçapava)].
2. Dentro desse filtro, manter apenas SIT_ATIV = 'AT' (unidades ativas).
3. Selecionar apenas as colunas do esquema reduzido de cada tabela (Seção 4).
4. Agregar as colunas mensais de DIC e FIC em totais anuais (e demanda/energia, se decidido usá-las).
5. Padronizar os tipos de dado (texto para códigos, numérico para coordenadas e cargas).
6. Carregar em três tabelas separadas no banco (ucat_pj, ucmt_pj, ucbt).
7. Validar que os valores de CONJ das três tabelas realmente se cruzam na área das duas cidades, antes de usar essa chave para agrupar pontos de níveis de tensão diferentes.

7. Números já confirmados por cidade (São José dos Campos + Caçapava)

Nível	Total no filtro por cidade	Ativas (SIT_ATIV = 'AT')
Alta Tensão (UCAT_PJ)	23	20
Média Tensão (UCMT_PJ)	844	678
Baixa Tensão (UCBT)	Pendente — depende do recorte do CSV de 5 GB	Pendente

Assim que um recorte filtrado (ou uma amostra) do CSV de baixa tensão for enviado, esses números podem ser completados e a sobreposição real de CONJ/SUB entre os três níveis, validada com dados concretos — do mesmo jeito que já foi feito entre UCAT_PJ e UCMT_PJ.

8. Resumo executivo

- Os três arquivos (UCAT_PJ, UCMT_PJ, UCBT) são a mesma base regulatória BDGD/ANEEL, cada um em um nível de tensão, ligados por uma hierarquia elétrica real: SUB → CTAT → UCAT | SUB → UNI_TR_AT → CTMT → UCMT | SUB → UNI_TR_AT → CTMT → UNI_TR_MT → RAMAL → UCBT.
- CONJ é a chave mais confiável para unir os três níveis (100% de correspondência testada entre AT e MT); SUB é o vínculo eletricamente correto mas com sobreposição parcial; os identificadores de conexão (COD_ID_ENCR, PN_CON, PAC, RAMAL) nunca ligam as tabelas entre si.
- Recomenda-se três tabelas separadas no banco, com esquemas reduzidos de ~15 colunas cada, e uma dimensão auxiliar opcional (dim_conjunto) para evitar repetição de metadados de topologia.
- Faltam apenas os números reais da baixa tensão nas duas cidades — dependem de um recorte filtrado do CSV de 5 GB ser enviado.